

计算机系统概论（2025 秋）作业 1 答案

班级：_____ 姓名：_____ 学号：_____

一、填空题

1. 在所有由四个“1”和四个“0”组成的 8 位二进制整数（补码形式）中，最大的数是 01111000，最小的数是 10000111，绝对值最小的数是 00001111（答案用二进制表示）。
2. 已知 $[X]_{\text{补}} = 0x2025$ ， $[Y]_{\text{补}} = 0xFADE$ ，则 $[X + Y]_{\text{补}} = \underline{0x1B03}$ ， $[X - Y]_{\text{补}} = \underline{0x2547}$ （ X 、 Y 的数据位宽均为 16 位，计算结果用 16 进制的补码表示）
3. FP8 是一种 8 位浮点数类型，常见于大模型混合精度训练或量化推理。常用的 FP8 有两种表示格式：E4M3 和 E5M2。其中 E4M3 由四个指数位、三个尾数位和一个符号位组成。E5M2 由五个指数位、两个尾数位和一个符号位组成。
 - (1) E4M3 所能表示的最大的非规格数是 00000111，E5M2 所能表示的最大规格数是 01111011（答案用二进制表示）。（提示：这里可以使用 IEEE 浮点数标准处理）
 - (2) 当模型训练过程中需要使用 FP8 表示最小的大于 0 的浮点数时，E5M2（填 E4M3 或 E5M2）格式更加精确，这个数字是 $\frac{1}{65536} = 1.526e - 5$ （答案用十进制表示）。
4. FP16 是另一种 16 位浮点数（符合 IEEE 浮点数标准），也常见于大模型混合精度训练。FP16 的指数位数是 5，尾数位数是 10，符号位数是 1。某同学将该格式的一个数 x 的二进制位串视作 16 位整数，执行了一次按位右移操作，得到了 160.75。若右移操作是算术右移，则原来的数可能是 不存在；若右移操作是逻辑右移，则原来的数可能是 $-\frac{1549}{8192} = -0.18909$ 或 $-\frac{387}{2048} = -0.18896$ （填入所有可能情况或“不存在”，使用十进制表示，可以使用小数或分数）

二、简答题

5. 某同学在进行大模型训练时使用 8 位的字长进行数值表示。
 - (1) 8 位能表示的定点数个数多还是浮点数个数多？为什么？
定点数多。所有的八位二进制串均对应一个定点数，但浮点数中部分二进制串对应 NaN 或 Inf。
 - (2) 该同学在面临下述环境时，应该选用什么样的数据类型（INT8、FP8-E5M2、FP8-E4M3）？给出你的选择并作出合理解释即可。
 - 在模型训练过程中出现梯度爆炸（模型参数数值大小趋向于 ∞ ）
FP8-E5M2。有更多的指数位，能表示的数上界更大。

- 在模型训练过程中出现梯度消失（模型参数大小趋向于 0）

FP8-E4M3. 有更多的尾数位，在 0 附近分辨能力更强.

FP8-E5M2. 有更多的指数位，能够表示更小的趋向于 0 的数.

理由合理即可.

- 模型训练完成后上线部署（模型计算过程中数值相对稳定）

INT8. 数值区间稳定后能够表示的数字更多，表达能力更强.

FP8-E4M3. 有更多的尾数位，能够在稳定范围内提供更高精度.

理由合理即可.

6. 使用不超过 4 次位运算或加减法运算完成整数运算 $y = x \times 45$ (允许引入临时变量，不需要考虑溢出的情况).

$a=x \ll 2, b=a+x, c=b \ll 3, y=b+c$ 或 $a=x \ll 3, b=a+x, c=b \ll 2, y=b+c$