

计算机系统概论（2025 秋）作业 1

班级: 计42 姓名: 张芝源 学号: 2024010701

$$2^4 (-8+4+2+1)$$

一、填空题

1. 在所有由四个“1”和四个“0”组成的 8 位二进制整数（补码形式）中，最大的数是 01111000，最小的数是 10000111，绝对值最小的数是 00001111（答案用二进制表示）。

$$11110000 \text{ or } 00001111 \quad -2^7+2^6+2^5+2^4 = -16$$
$$2^0+2^1+2^2+2^3 = 15$$

2. 已知 $[X]_{\text{补}} = 0x2025$, $[Y]_{\text{补}} = 0xFADE$, 则 $[X+Y]_{\text{补}} = \underline{0x1B03}$, $[X-Y]_{\text{补}} = \underline{0x2547}$ (X 、 Y 的数据位宽均为 16 位, 计算结果用 16 进制的补码表示)

$$\begin{array}{r} 2025 \\ FADE \\ \hline 11B03 \end{array} \quad \begin{array}{r} 2025 \\ FADE \\ \hline 2547 \end{array}$$

3. FP8 是一种 8 位浮点数类型, 常见于大模型混合精度训练或量化推理。常用的 FP8 有两种表示格式: E4M3 和 E5M2。其中 E4M3 由四个指数位、三个尾数位和一个符号位组成。E5M2 由五个指数位、两个尾数位和一个符号位组成。

(1) E4M3 所能表示的最大的非规格数是 00000111, E5M2 所能表示的最大规格数是 01111011 (答案用二进制表示)。 (提示: 这里可以使用 IEEE 浮点数标准处理)

(2) 当模型训练过程中需要使用 FP8 表示最小的大于 0 的浮点数时, E5M2 (填 E4M3 或 E5M2) 格式更加精确, 这个数字是 $\frac{1}{65536}$ (答案用十进制表示)。

非规格化

4. FP16 是另一种 16 位浮点数 (符合 IEEE 浮点数标准), 也常见于大模型混合精度训练。FP16 的指数位数是 5, 尾数位数是 10, 符号位数是 1。某同学将该格式的一个数 x 的二进制位串视作 16 位整数, 执行了一次按位右移操作, 得到了 160.75。若右移操作是算术右移, 则原来的数可能是 不存在; 若右移操作是逻辑右移, 则原来的数可能是 $-\frac{387}{2048}$ 或 $-\frac{1549}{8192}$ (填入所有可能情况或“不存在”, 使用十进制表示, 可以使用小数或分数)

二、简答题

5. 某同学在进行大模型训练时使用 8 位的字长进行数值表示。

(1) 8 位能表示的定点数个数多还是浮点数个数多? 为什么?

定点数多, 它可表示 2^8 个数。

浮点数的话要去除 NaN (指数域都是 1) 和 ± 0 , 所以比 2^8 少

(2) 该同学在面临下述环境时, 应该选用什么样的数据类型 (INT8、FP8-E5M2、FP8-E4M3)? 给出你的选择并作出合理解释即可。

• 在模型训练过程中出现梯度爆炸 (模型参数数值大小趋向于 ∞)

INT8 范围 $[-128, 127]$
E5M2 范围 $[-51344, 51344]$
E4M3 范围 $[-240, 240]$

仅表示最大, 最小值是离散的

$$01111011 \quad 11$$
$$1.75 \times 2^{15}$$

$$E = 30 - 15 = 15$$

$\therefore$ 选 FP8-E5M2, 它有更大的动态范围

- 在模型训练过程中出现梯度消失（模型参数大小趋向于 0）

不选 INT-8, 因为只能表示整数
 大于 0 的最小值: $\begin{cases} \text{E5M2} & 2^{-14} \\ \text{E4M3} & 2^{-6} \end{cases} \therefore \text{选 FP8-E5M2}$

- 模型训练完成后上线部署（模型计算过程中数值相对稳定）

选 INT8, 因为分布均匀, 其计算过程中速度最快, 功耗最低

- 使用不超过 4 次位运算或加减法运算完成整数运算 $y = x \times 45$ (允许引入临时变量, 不需要考虑溢出的情况).

2次(加) 1次(左移3位)
 $\text{temp} = x + (x \ll 3) \quad (9x)$
 4次(加) 3次(左移2位)
 $y = \text{temp} + (\text{temp} \ll 2)$